TraceHub

面向下游（调用方）的核心优势

OpenAI 兼容 · 一次对接 · 多模型统一出口

少写集成 · 少背运维 · 成本可算 · 协议不变

官网 / 控制台：http://182.92.159.29/

API Base URL：http://182.92.159.29

接入文档：http://182.92.159.29/docs

适用对象：应用开发者 · Agent 平台 · SaaS · 企业内部 AI 出口

核心价值（一句话）

> 只改 Base URL 和 API Key，原有 OpenAI SDK / 客户端继续用；背后多模型、多线路、路由与计费由网关代劳。

迹径 TraceHub 是 OpenAI 兼容的 AI API 统一网关。对下游（应用、Agent、SaaS、内部工具）而言：少写集成、少背运维、成本可算、协议不变、能力可扩。

1. 接入成本极低：一套协议走天下

下游痛点	TraceHub 给什么
每家模型一套 SDK、鉴权、流式格式	统一 /v1 OpenAI 风格接口；对话、模型列表与生态习惯一致
换模型要改代码	改 model 参数即可；模型别名对外稳定、背后换线透明
从 OpenAI 迁出成本高	迁移 ≈ 两行配置：baseURL + apiKey；LangChain 等多数可直接复用

结果：精力花在产品与 Prompt，而非 N 家厂商 × M 套适配器。

2. 调用体验稳定：流式、工具调用、多模态

- SSE 流式完整支持；多上游统一为 OpenAI 风格 chat.completion.chunk，客户端无需按厂商分叉解析。
- 能力矩阵（以配置为准）：对话、补全、Embeddings、图像、音频、视频、Realtime 等同一 /v1 体系扩展。
- 工具调用 / 多模态按 OpenAI 兼容请求体传递，无需为每条线路单独造轮子。

结果：Agent、Copilot、客服机器人协议层一次定型，模型选型变成配置问题。

3. 可靠性由网关兜底

- 健康准入：异常线路自动退出选路池。
- 自动故障转移：网络失败、5xx、429 等可换渠道重试（有上限；流式已输出不再切换）。
- 多通道池化 + 权重/优先级：分散压力或按「先 A 后 B」运维。
- 粘性会话（可选）：长对话同会话固定线路，失效后回退普通选路。

结果：业务只打一个稳定入口，线路抖动由网关吸收。

4. 成本可预期、可对账

- 按 Token 精确计量：输入/输出分开计价，规则控制台可对齐说明。
- 灵活倍率：分组、用户、单模型维度，支持普通价 / 会员价 / 内测价。
- 按次计费与混合模式：适合图像、视频、固定单价类 API。
- 免计费模型（可配置）：联调灰度可不扣额度，仍可记日志。
- 调用日志：时间、模型、Token、费用、状态码可追溯，便于对账与排障。

结果：财务与研发用同一套数据，避免账单对不上。

5. 安全边界清晰

- 下游只持平台 API Key；上游渠道密钥 AES 加密存服务端，不进仓库与客户端。
- 用户 Key 哈希保存；管理端敏感操作可审计留痕。
- 可拦截云端控制台类 /v1 路径，降低账号管理 API 误暴露风险。
- 可选：邮件验证码、图形验证码、/metrics Bearer 保护（依赖运营配置）。

结果：适合多租户 SaaS 与企业统一出口，应用侧攻击面更小。

6. 可观测、可扩容

- /health、/ready：K8s 探针友好。
- /metrics（Prometheus）：QPS、延迟、错误率接入现有监控。
- 无状态水平扩展：加实例 + 负载均衡即可。
- Go 高并发转发，面向 API 低延迟场景优化。

结果：当作标准基础设施组件接入，而非黑盒脚本。

7. 控制台与生态

- 官网 + 用户控制台：注册、Key、余额用量、兑换码、改密自助闭环。
- 多语言：简中 / 繁中 / English。
- 分组默认模型、CORS：减少 Web/H5 漏传 model 失败。
- 开源 MIT + Docker Compose：托管或私有化/二次品牌化均可。

结果：从个人试调到企业内网网关，同一产品骨架可承接。

8. 谁最适合接入？

- 产品 / 研发：快速 A/B 多模型，不想维护多套集成。
- Agent / 自动化：依赖流式 + Tool Calls + 稳定 Base URL。
- SaaS：统一出口与计量，AI 成本摊到租户或项目。
- 初创 / 项目制：可预期单价 + 可导出日志，支撑报价与复盘。

9. 三步开始

1. 注册 → 控制台创建 API Key（仅创建时完整展示，请妥善保存）。
2. 将客户端 baseURL 指向网关（当前示例：http://182.92.159.29，路径以文档为准）。
3. Authorization: Bearer <平台 Key>，设置 model，即可联调。

余额不足可能返回 HTTP 402，便于程序侧引导充值。

宣传语（海报 / 落地页）

主标语

> 多模型，一条链路 —— OpenAI 兼容，一次接入。

副标语（任选）

- 改两行配置，不换开发习惯。
- 路由、Failover、计费、日志，网关全包，你只写业务。
- Token 透明、按次可配、日志可对账，AI 成本看得见。
- 流式统一、工具调用即用，Agent 上线更快。
- 开源可私有化，托管可即开即用。

电梯演讲（约 30 秒）

TraceHub 把多家大模型收敛成一套 OpenAI 兼容 API。下游换 Base URL 和 Key，SDK 照旧；换模型只改参数。网关负责多线路调度、故障转移、流式对齐、Token/按次计费与调用日志，并提供控制台与可选私有化。团队专注产品，集成与运维交给平台。

说明边界

以下依赖运营配置与部署版本，对外请注明「以实际上线为准」：

- Failover 次数、粘性会话、透传白名单、Realtime、免计费模型名单。
- 在线支付、OAuth、细粒度 RBAC、语义缓存等见路线图，非默认必交付。

完整能力见仓库 README.zh-CN.md、docs/产品文档.md、docs/TraceHub-客户接入宣传.md
本文档生成：scripts/generate_downstream_promo_pdf.py