多模型 AI 推理，一站接入

OpenAI 兼容接口 · 一次对接，调用 GPT / Claude / Gemini / DeepSeek 等主流模型

把精力放回产品与业务，把「多供应商、多协议、多 Key 轮换」交给平台。

新用户与共创激励

• 新用户礼遇：完成注册后，即赠送 约 ¥2
等额调用额度（按平台额度与计费规则折算，自动到账），便于零成本试调接口与模型。

• 反馈有礼：您在使用过程中 反馈有效问题、复现步骤或产品建议，经运营方核实后，可获赠
额外调用额度（具体标准、次数与上限以当期活动或工单回复为准）。

性能体验：为 API 调用而设计

• 高性能技术栈：网关基于 Go 与轻量 Web 框架构建，面向 高并发、低延迟 的 API
转发场景优化，适合作为统一出口承接线上流量。

• 流式输出：完整支持 SSE 流式对话；多上游响应在平台侧对齐为一致的
分片流格式，降低客户端与网关之间的解析与缓冲成本。

• 易扩展部署：业务上可按需 水平扩展
网关实例（配合负载均衡），流量增长时以「加机器」方式平滑扩容。

• 可观测闭环：提供 Prometheus 指标、存活 /
就绪探针，便于接入现有监控与告警，性能与稳定性「看得见」。

上游与高可用：降低「单点断服」风险

平台在调度与转发层采用多重策略，在单条上游抖动时尽量自动绕行，减少对您业务的感知（具体策略以运营方为您所在分组开启的配置为准）。

策略	说明
健康准入	仅向 健康、已启用且可参与调度 的渠道分配流量，异常线路自动暂不参与选路，避免「明知不可用仍撞上去」。
自动故障转移（Failover）	当遇到 网络传输失败、5xx 服务端错误、429 限流 等可恢复类问题时，可在配置范围内 自动更换渠道重试（重试次数有上限，且流式响应已开始输出时不再切换，避免破坏客户端协议）。
多通道池化	同一模型可配置 多条上游线路，配合 权重随机 或 优先级 等策略分散压力；亦可按模型配置固定优先顺序，满足「先走 A、再走 B」的运维诉求。
稳健度偏好	在多条候选线路中，结合 历史错误计数 等信号，优先在更稳定的子池内做加权选择，降低「坏线反复被抽到」的概率。

粘性会话	可选启用 Redis 粘性会话：同一用户在同一会话键下尽量命中同一上游，长对话、工具链调用更连贯；会话失效或线路不可用时自动回退到正常选路。
健康与探测（可选）	支持按分组开启 基于探测的自动健康治理 等能力，与人工标记健康状态相结合，便于长期运维。

您还将获得这些亮点

亮点	说明
统一协议	客户端继续使用熟悉的 OpenAI 风格 `POST /v1/chat/completions` 与 `GET /v1/models`，无需为每家模型单独维护一套集成。
模型别名	支持 逻辑模型名 → 实际上游模型名 映射，对外接口稳定、背后切换供应商时对您透明。
透明计费	按 Token / 用量 计费，规则清晰；支持分组与模型维度的 倍率策略，成本可预期、可对账。
不计费模型（可选）	运营方可配置 免计费模型清单：对指定逻辑模型 调用不扣额度，便于联调、灰度与低成本试错；分组侧亦可对单模型单独覆盖 是否计费。不计费时仍可记录调用日志，用量可观测、可治理（具体名单与规则以平台公示为准）。
安全默认	可拦截易被误用的 云端控制台类路径，降低将「账号管理类 API」暴露给终端用户的风险（以平台配置为准）。
密钥与审计	上游凭据 加密存储；用户 API Key 哈希保存；管理端关键操作可 审计留痕，满足内控与溯源需求。
快速上线	注册 → 创建 API Key → 修改 Base URL 即可联调；叠加 新用户约 ¥2 试用额度、兑换码 等，降低接入门槛。
生态扩展	除主流厂商外，可按运营配置接入更多 OpenAI 兼容协议 的上游类型；亦可在白名单控制下 按需透传 更多 `/v1` 能力，兼顾扩展与安全边界。
控制台体验	官网 + 用户控制台 + 用量/日志 一体；界面支持 简中 / 繁中 / English 等多语言，便于跨区域团队使用。
账号与接入安全	可启用 邮件验证码登录、登录图形验证码 等能力，降低撞库与滥用风险（依赖运营方开启与邮件服务配置）。

私有化友好	项目 开源（MIT），支持 Docker Compose 一体化部署与 单二进制托管前端，适合自托管或二次品牌化交付。

更多可对外强调的能力（视版本与运营配置）

• 分组默认模型：可为不同用户组配置 默认模型，减少客户端漏传、错传 `model` 导致的失败。

• 跨浏览器调用：服务端可配置 CORS，Web 与移动端 H5 直连网关更顺畅。

• 运维侧安全：指标接口可配合 Bearer 鉴权 或内网访问策略，避免监控数据对外裸奔。

• Realtime 语音场景：若运营方开启相关能力，可对 Realtime 通话子资源
做映射与策略配置（详见平台说明），服务语音/实时类应用。

• 调用与对账：请求落
用量日志，便于您做成本分析、问题定位与对账导出（以控制台开放能力为准）。

适合哪些团队

• 产品 / 研发团队：要在应用里快速切换或组合多款大模型，又不想维护多套 SDK 与账号池。

• 内部效率工具：希望统一出口、统一用量与成本，便于分摊与治理。

• 初创与项目制交付：需要可预期的调用成本与清晰的用量日志，支撑报价与复盘。

三步开始接入

注册账号并完成基础认证（具体以平台开放能力为准）。

在控制台 创建 API Key，妥善保管（仅创建时完整展示）。

将现有 OpenAI 兼容客户端的 Base URL 指向本平台（当前为
`http://182.92.159.29`，常见为拼接 `/v1/...`，以接入文档为准），Authorization
使用平台下发的 Key，按需调整 `model` 名称即可开始调用。

访问地址与域名

• 当前正式入口（IP）：官网与用户控制台 `http://182.92.159.29/`（线上环境：迹径 · TraceHub — 循迹未来）。

• API Base URL（当前）：`http://182.92.159.29` — 接入后将客户端原 OpenAI Base URL 替换为此地址即可联调。

• 域名审核通过后（敬请期待）：官网 `www.tracefuture.cn`，API 专用域名
`api.tracefuture.cn`；解析与 HTTPS 启用时间以运营方公告为准，上线后 Base URL
将同步切换为
`https://api.tracefuture.cn`（或运营方最终公布的基址，请以届时文档为准）。

我们坚持的承诺

• 计费与规则透明：单价与计量方式可对齐说明，减少「黑盒加价」带来的不信任。

• 稳定与可观测：健康检查、指标与日志能力便于与您现有运维体系对接。

• 持续扩展模型生态：在统一接口之上持续接入更多主流与高性价比模型，您侧重选型与业务创新即可。

立即行动

打开 `http://182.92.159.29/`
注册/登录，获取接入文档、费率表与测试额度；或联系运营方协助开通。域名 `www.tracefuture.cn` / `api.tracefuture.cn` 审核通过后将另行公告切换方式。

本文档用于宣传「接入使用本平台 AI 接口」。访问地址与域名以运营方实时公告为准；新用户额度、反馈赠额、不计费模型名单等活动与策略以站内说明为准；Failover、粘性会话、路由策略、透传扩展、邮件/验证码登录、Realtime、CORS
等依赖运营方配置与部署环境；产品能力以实际上线版本与运营说明为准。