TraceHub 产品介绍（销售版）

1. 一句话定位

TraceHub 是一套开源的 AI API 网关 / 中转平台：把 OpenAI、Claude、Gemini、DeepSeek 等多种上游，统一收敛为 一套 OpenAI 兼容的 `/v1` 接口，并配套 用户体系、API Key、分组与模型倍率、用量与计费、管理后台与营销官网，适合自建「模型聚合 + 精细化运营」的中转站或企业内部网关。

2. 目标客户与场景

客户类型	典型诉求	TraceHub 如何契合
独立开发者 / 小团队	想一次接入多模型、少改代码	OpenAI 兼容协议，现有 SDK /客户端多数可直接指向网关
中小企业 / 内部平台	要统一入口、成本与权限可管	用户、Key、分组倍率、用量日志、管理端一站式
准备做 AI 中转/聚合服务	要可运营、可扩展、可私有化	计费与兑换码、站点品牌化配置、Docker 一键栈、Prometheus 指标
技术型组织	要可控、可审计、可观测	密钥加密存储、审计日志、健康检查与 `/metrics`

3. 商业价值（核心卖点）

统一接入，降低集成成本

下游只对接 OpenAI 风格 API；上游可以是 OpenAI 协议、原生 Claude、原生 Gemini 等，由网关完成协议与流式输出的对齐。

可运营的「商业化骨架」

用户注册登录、API Key（哈希存储）、余额与用量、兑换码、分组与模型倍率等，支撑「拉新—转化—留存」的基础运营闭环。（在线支付等能力见项目路线图。）

调度与计费可解释、可调参

按分组与模型筛选渠道、加权随机路由；可选 Redis 粘性会话；计费侧支持 Token 估算与扣减、分组 / 用户 / 单模型 相关倍率参与计价；并支持 全局免计费模型 与分组级计费开关等灵活策略。

安全与合规友好设计

上游渠道密钥 AES-GCM 加密存储；管理端敏感操作 审计日志；可选 登录图形验证码、邮件验证码登录/注册；`/metrics` 可配置 Bearer 保护。

部署形态灵活

支持 Docker Compose 一体化环境；前端构建产物可由 Go 单进程托管 SPA，适合轻量上线。

4. 功能亮点（当前版本已实现）

4.1 网关与协议兼容

• `POST /v1/chat/completions`：支持 SSE 流式；OpenAI 兼容上游可直接转发。
• 原生 Claude / Gemini 渠道：将上游流式结果转为 OpenAI 风格的 `chat.completion.chunk`，下游集成成本低。
• `GET /v1/models`：返回对用户可用的模型列表。
• 安全默认：可配置拦截 `/v1` 下部分 OpenAI 账号/控制台类路径，降低误暴露风险。
• 可选透传：按白名单透传更多 `/v1/*`（默认关闭），满足进阶扩展。

4.2 智能路由

• 按用户 分组 + 模型 筛选渠道；优先级 + 权重 随机选择。
• 可选 Redis 粘性会话：同一会话尽量固定上游，改善连续对话体验。

4.3 计费与额度

• Token 估算与实际用量 驱动的额度扣减。
• 分组倍率、用户维度、单模型倍率 组合计价。
• 全局不计费模型 与分组覆盖；不计费仍可记录用量日志。

4.4 用户侧

• 注册 / 登录（JWT）、修改密码。
• API Key 管理；Key 哈希存储。
• 余额与用量、兑换码兑换。
• 邮件验证码（SMTP 可配置）；可选 简中 / 繁中 / English 邮件策略。
• 登录图形验证码（依赖 Redis 时可开启）。

4.5 管理后台

• 用户与渠道管理；渠道密钥 加密落库。
• 分组与模型倍率、调用日志查询。
• 兑换码批量生成与核销。
• 审计日志。
• 站点与品牌：版本号、运营方展示名、CORS、新用户默认额度、注册推广文案等可配置；支持本地上传品牌图标。

4.6 前端

• 营销官网：Hero、模型展示、价格与 FAQ。
• 用户控制台、管理后台。
• 多语言文案支持（简中 / 繁中 / English 等）。

4.7 可观测性与运维

• `/health`、`/ready`。
• `/metrics`（Prometheus）。
• 配置集中 YAML，便于多环境发布。

5. 技术架构摘要

维度	说明
后端	Go 1.25+、Gin、Ent ORM、PostgreSQL
缓存	Redis 7+（可选；部分能力无 Redis 时降级）
前端	Vue 3、Vite、Tailwind CSS v4、Pinia、Vue Router
许可证	MIT

6. 路线图说明（售前对齐）

部分能力在产品愿景与 `docs/development-docs/milestones-roadmap.md` 中规划，例如：在线支付（支付宝/微信/Stripe）、OAuth 登录、更细粒度 RBAC、Webhook、语义缓存等。以仓库 README 中「已实现能力概要」为准做投标与交付边界；完整愿景见 `docs/■■■■.md`。

7. 定价与「倍率」沟通建议（运营附录）

• 对客户：优先讲清 最终单价与计费规则（如每百万 token 对应额度/人民币）；可用「不同分组不同折扣」表述，不必逐条暴露后台倍率数字。

• 起步调价：在已覆盖上游成本与运维成本的基准上，拉新阶段分组倍率常见试水区间为 0.9～0.95；再低建议配合限时活动或兑换码，避免长期全站亏损。

8. 行动号召（CTA）

• 技术验证：使用仓库内 Docker Compose 拉起栈，验证「注册 → API Key → 调模型 → 日志与扣费」全链路。

• 商务定制：支付对接、企业 SSO、合规字段等建议在 POC 清单中明确接口与合规要求后再评估工时。

文档版本：与销售对话整理一致；产品以开源仓库 README 与发布说明为准。